

陨石图片二分类项目中期报告

第 8 组：杨一鸣、徐政男、陆鎏安、鞠欣成

Kaggle 用户名：yang-yi1ming (ConvNeXt), JacobLi0910 (EfficientNet)

2026 年 5 月 8 日

摘要

本项目目标是完成陨石图像二分类。数据共 5609 张图像，其中训练集 5098 张、测试集 511 张，且训练集与测试集存在类别先验和图像分布偏移。我们尝试了 EfficientNetV2、DINOv3 和 ConvNeXt 等预训练视觉模型，并结合两阶段微调、Bayes 先验校正、测试时增强 (TTA)、数据清洗和模型集成进行优化，当前最佳 Kaggle F1-score 为 **0.78761**。数据分析显示，随机验证集分数异常接近 0.99 主要来自背景、展柜、标签和拍摄环境的重复；自建验证集、SAM 去背景实验与 ConvNeXt embedding 聚类共同说明，背景相似性是数据泄露的重要来源。下一阶段重点是基于背景簇构造可靠验证集，在可信验证集上细调超参数，并降低模型对背景的依赖。

1 数据集理解

1.1 数据来源与描述

任务数据为图片二分类数据集，标签为“陨石”和“非陨石”。每个样本的原始特征是 RGB 图像，因此特征类型为高维非结构化视觉特征；经过预训练模型后，可被映射为深度表征向量，再接线性分类头输出陨石概率。当前数据共 5609 张图像，其中训练集 5098 张、测试集 511 张。题目说明测试集类别先验约为非陨石：陨石 = 4.06 : 1，而训练集正负比例接近 1 : 1，这意味着训练分布与测试分布存在明显先验偏移。

1.2 探索性数据分析

本项目首先暴露出的问题是验证集数据泄露。我们最初使用随机 train/validation = 8:2 划分，模型在约 10 个 epoch 后即可达到接近 0.99 的 validation F1/accuracy，但 Kaggle 测试集表现仅约 0.7。这说明随机验证集与训练集之间存在数据泄露问题，离线评估基本不可用。

为获得更可信的离线反馈，我们从图像网站额外收集陨石、普通岩石和 “meteorite wrong” 等关键词图片，构建了一个自建 validation set（训练曲线见图 3）。它能粗略比较模型变种，但 F1 曲线抖动明显，且与 Kaggle 排名不完全一致。因此，自建集只能作为调试和压力测试工具。

为进一步定位泄露来源，我们使用 SAM 对图像主体进行分割并移除背景（见图 4）。去背景后，随机验证集曲线变得更正常，最高验证 F1 约为 0.702，但 Kaggle 分数下降到约 0.500；反过来，仅使用背景训练时，验证集又出现接近 0.99 的异常高分。因此我们怀疑，随机验证集的数据泄露主要来自背景相似性，而非石头主体本身的重复。这也解释了自建集不稳定的原因：它改变了背景分布，却未必更接近官方测试集。

我们进一步用 ConvNeXt-tiny embedding 对原图、SAM 主体图和反向 mask 背景图分别做 HDBSCAN 聚类，并用 UMAP 可视化 train/test 的分布。聚类结果见表 6，主体与背景的 UMAP 对照见图 1。背景图的聚类结构明显强于石头主体：训练集中，主体图只有 2 个簇且噪声达到 92%，而背景图有 6 个簇且噪声仅 40%；测试集中，主体图为 0 个簇、100% 噪声，背景图仍有 2 个簇且噪声仅 15%。这说明背景上下文比石头外观更容易形成稳定簇，模型很可能借助背景相似性获得虚高验证分数。

基础统计同样显示 train/test 存在分布差异（完整统计见表 4 和表 5）。训练集平均尺寸为 1077×877 ，测试集为 899×767 ；resize 到 224×224 并归一化到 $[0, 1]$ 后，训练集 RGB 平均亮度约为 0.547，测试集约为 0.502。相比 ImageNet 常用归一化参数 $\mu = 0.485, \sigma = 0.229$ ，本数据整体更亮且像素方差更大。




图 1: 主体与背景 embedding 的 UMAP 可视化

1.3 数据预处理

目前已执行或尝试的预处理包括：统一输入分辨率、标准化、随机水平翻转、旋转、CutMix、测试时增强、手动数据清洗、基于 k-NN latent 的离群样本检查，以及使用 SAM 提取主体或反转 mask 分析背景影响。标准化和数据增强用于提升预训练模型微调稳定性；手动清洗用于移除毛巾、壁画、蓝色盆子、手、尺子等明显偏离任务语义或可能误导模型的样本；SAM 实验主要用于诊断背景泄露，而不是当前最终方案。

2 初步实验结果

2.1 模型选择与实验设置

我们先后尝试 EfficientNetV2 [2]、DINOv3 [3] 和 ConvNeXt [1]。EfficientNetV2 训练速度较快，适合早期快速迭代；DINO 表征理论上更强，但在小样本二分类中容易过拟合且对学习率敏感；ConvNeXt 兼具 CNN 的局部纹理归纳偏置和现代预训练模型的表达能力，微调更稳定，因此成为当前主线模型。

训练上，我们采用“两阶段微调”：先冻结 backbone，仅训练随机初始化的分类头 2–5 个 epoch，再解冻 backbone 全量微调，以避免早期混乱梯度破坏预训练特征。backbone 使用 layer-wise learning rate decay (LLRD)，典型 decay 取 0.8；优化器使用 AdamW。ConvNeXt baseline 中分类头学习率约为 1×10^{-3} ，backbone 学习率约为 1×10^{-5} ；batch size 为 256，训练 25 个 epoch，输入分辨率为 224×224 ，weight decay 为 0.05，dropout 为 0，label smoothing 为 0；主要实验固定随机种子为 42。此外，我们还使用 Bayes 先验校正处理训练集与测试集类别比例不同的问题。

具体而言，设模型在训练分布下输出正类概率为 p_s ，训练集和测试集正类先验分别为 π_s 与 π_t 。若假设 $P(x | y)$ 不变，则测试分布后验可通过 logit 平移近似修正：

$$\text{logit}(p_t) = \text{logit}(p_s) + (\text{logit}(\pi_t) - \text{logit}(\pi_s)).$$

该方法避免了在不可靠验证集上进行阈值搜索，也能直接利用题目给出的测试集类别比例。

2.2 结果分析

表 1: 主要模型与策略的初步结果

模型/版本	关键策略	Kaggle F1	分析
DINO v1	基础微调	0.59393	小样本下 ViT 微调不稳定，且未处理测试先验偏移。
DINO v2	Bayes 先验校正	0.70542	直接提升约 11 个百分点，说明类别先验偏移是核心问题之一。
DINO v6	先训 head 再解冻	0.74766	两阶段训练能显著稳定微调过程。
EfficientNet v7plus	Focal Loss + 部分数据清洗	0.78431	速度快、可迭代性强，但最终与 ConvNeXt 融合时权重较低。
ConvNeXt baseline	ConvNeXt-tiny-IN22k + LLRD + Bayes 校正 + 4-way TTA	0.78048	当前最稳定的单模型主线。
ConvNeXt ensemble	6 个 ConvNeXt/ConvNeXtV2 基座概率平均	0.78571	bagging 降低方差，小幅提升。
最终提交	ensemble + OCR 规则修正	0.78761	发现部分测试图含“陨石”字样，规则修正后进一步提升。




图 2: 不同 backbone 的训练曲线

结果显示, Bayes 校正、两阶段微调、合理 TTA、数据清洗和集成都带来了有效增益, 不同 backbone 的训练曲线见图 2, 更完整的 EfficientNetV2 与 DINO 实验记录见附录 A.1 和附录 A.2。其中 Bayes 校正的收益最大且解释性最强; 4-way TTA 优于更激进的 8-way TTA, 说明旋转、翻转等增强需要控制幅度, 过强几何变换可能破坏陨石纹理。另一方面, 随机验证集的异常高分提醒我们, 当前模型仍可能利用背景捷径, 因此离线 validation 分数不能直接作为泛化能力证据。

3 计划提升方向

基于目前实验, 后续提升的核心不应是继续盲目堆叠模型, 而应先解决评估体系, 再在可靠评估下优化模型。

第一, 基于背景簇构造更可靠的 validation set。目前最大瓶颈是随机验证集存在背景泄露, 而自建 validation set 又受到外部图片背景分布影响。下一步应利用原图与背景图的 embedding 聚类结果, 将相似展柜、标签、尺子、拍摄环境或网站风格的样本划入同一 group, 再进行 group split, 避免同一背景簇同时出现在训练集和验证集中。这样得到的验证集虽然可能更难, 但能更真实地反映模型是否学到了可泛化的陨石特征。

第二, 在可靠验证集上重新细调超参数和模型选择。之前由于缺少可信 validation set, 很多超参数只能依赖 Kaggle 提交或不稳定的自建集判断, 难以细致比较。构造新的 group validation 后, 应系统评

估学习率、LLRD decay、weight decay、数据增强强度、TTA 方式、Focal Loss 参数、输入分辨率和不同 backbone 的效果，并记录均值与方差，而不是只看单次提交分数。这样可以区分真正有效的训练策略和偶然适配测试集背景的策略。

第三，提升模型对石头主体的判断能力并降低背景依赖。 SAM 与聚类实验说明，当前模型很容易利用背景捷径，而纯主体图上的判别能力不足。后续可以尝试主体图与原图联合训练、随机模糊或替换背景、对背景相似样本做更强的数据增强，以及对真实 hard negative 进行有控制的重采样。目标不是完全删除背景信息，而是让模型在背景不可用或背景分布变化时仍能依靠形状、纹理、金属光泽和表面结构作出判断。

4 结论

目前项目已经完成多类预训练视觉模型的初步实验，并得到可用的 ConvNeXt 主线方案。当前最佳 Kaggle F1-score 为 **0.78761**，主要提升来自 Bayes 先验校正、两阶段微调、TTA、数据清洗、集成和少量规则修正。更重要的是，我们发现随机验证集由于背景和拍摄环境重复而严重高估性能；自建验证集、SAM 去背景/仅背景实验和 embedding 聚类共同指向同一结论：当前模型仍容易利用背景相似性，而不是稳定识别石头主体特征。

下一阶段的重点不是单纯增加模型复杂度，而是基于背景簇建立可靠验证集，在可信验证集上重新细调超参数，并设计减少背景依赖、增强主体判别能力的训练策略。若这些问题得到解决，模型选择和集成优化才会更有方向，最终结果也更可能稳定提升。

参考文献

[1] Liu, Z., Mao, H., Wu, C.-Y., Feichtenhofer, C., Darrell, T., & Xie, S. (2022). A ConvNet for the 2020s. *CVPR*.

[2] Tan, M., & Le, Q. (2021). EfficientNetV2: Smaller Models and Faster Training. *ICML*.

[3] Siméoni, O., et al. (2025). DINOv3. arXiv preprint arXiv:2508.10104.

[4] Kirillov, A., et al. (2023). Segment Anything. *ICCV*.

[5] Lin, T.-Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). Focal Loss for Dense Object Detection. *ICCV*.

A 附录：原始实验记录与补充图表

A.1 EfficientNetV2 版本记录

表 2: EfficientNetV2 版本改进记录

版本	主要改进	得分
v2	预训练权重；dropout=0.5, label smoothing=0.15, weight decay=0.04	0.68
v3	早期有效版本，具体超参待整理	0.70588
v4	TTA 3 折 + OOF + Platt + 软融合；训练成本增加但收益有限	0.70682
v5	Focal Loss, $\gamma = 2$ ；head lr=6e-4, backbone lr=1.2e-5, epoch=16	0.74509
v7	手动清洗 4 张明显问题图片	0.76470
v7plus	标记 20 张后再训练	0.78431
v7++	标记 97 张难例，可能清洗过度	0.7745
v10	加入 CosineAnnealingWarmRestarts	0.72146

A.2 DINO 后续实验记录

表 3: DINO 相关实验汇总

版本	策略	结果	分析
v6	先训 head 2 epoch, 再解冻	0.74766	两阶段微调有效。
v7	使用 train+test 微调以适应结构	0.69767	可能破坏原始特征并过拟合。
v8	输入分辨率提升到 448	0.68363	默认感受野与预训练设置不匹配。
v9	GeM Pooling 替换 CLS token	0.66165	GeM 与 DINO CLS 表征适配不好。
v10	LR scan	0.61290–0.71428	DINO 对学习率敏感。

A.3 训练曲线与数据诊断图

表 4: 原始图像尺寸统计


指标	Train (5098)	Test (511)	Total (5609)
宽度	1077 ± 762 (var=580k)	899 ± 1068 (var=1.14M)	1060 ± 797 (var=634k)
高度	877 ± 607 (var=368k)	767 ± 842 (var=709k)	867 ± 633 (var=400k)

表 5: 224 × 224 图像在 [0, 1] 空间下的像素统计


通道	Train	Test	Total
R	$\mu = 0.573, \sigma = 0.294 (\sigma^2 = 0.086)$	$\mu = 0.524, \sigma = 0.272 (\sigma^2 = 0.074)$	$\mu = 0.569, \sigma = 0.292 (\sigma^2 = 0.086)$
G	$\mu = 0.546, \sigma = 0.295 (\sigma^2 = 0.087)$	$\mu = 0.499, \sigma = 0.266 (\sigma^2 = 0.071)$	$\mu = 0.542, \sigma = 0.293 (\sigma^2 = 0.086)$
B	$\mu = 0.521, \sigma = 0.303 (\sigma^2 = 0.092)$	$\mu = 0.484, \sigma = 0.278 (\sigma^2 = 0.078)$	$\mu = 0.517, \sigma = 0.301 (\sigma^2 = 0.091)$
Avg	$\mu = 0.547, \sigma = 0.298 (\sigma^2 = 0.089)$	$\mu = 0.502, \sigma = 0.272 (\sigma^2 = 0.074)$	$\mu = 0.543, \sigma = 0.296 (\sigma^2 = 0.087)$

表 6: ConvNeXt embedding 的 HDBSCAN 聚类结果

输入变体	Train clusters/noise	Test clusters/noise
Full image	4 clusters, 49% noise	2 clusters, 90% noise
SAM stone foreground	2 clusters, 92% noise	0 clusters, 100% noise
SAM background	6 clusters, 40% noise	2 clusters, 15% noise




(a) 自建 validation set 上的 ConvNeXt 变种 F1 曲线




(b) 自建 validation set 上的 ConvNeXt 变种 best F1 曲线


图 3: 自建验证集上的模型变种诊断图




(a) SAM 去背景后的 validation F1 曲线



(b) SAM 去背景后的 best validation F1 曲线



(c) 反向 mask/背景图的 validation F1 曲线



(d) 反向 mask/背景图的 best validation F1 曲线

图 4: SAM 主体与背景对照实验