

陨石图像二分类项目报告

第八组：杨一鸣、徐政男、陆鎏安、鞠欣成

引言

本项目目标为预测测试图像是否为陨石，以 binary F1 作为主要评价指标。该任务的难点在于样本规模较小、背景和拍摄条件变化大、测试集与训练集存在明显分布偏移，以及陨石的判别信息往往隐藏在熔壳光泽、气印结构和矿物颗粒等局部纹理中。

我们以测试 F1 0.70222 的初始基线为起点，随后重点改进数据预处理、优化器、纹理 patch 训练、模型规模与集成策略，最终单模型 F1 达到 **0.79365**，三模型集成 F1 达到 **0.81633**。除最终结果外，本项目的研究价值还体现在大量负结果和诊断实验：验证集与测试集分布偏移、TTA 与多 patch 推理失效、Model Soup 失效、ConvNeXt V2 失效等现象共同帮助我们逐步定位真正有效的方向。

本项目方案基于本地深度学习模型训练、阈值搜索与概率集成，没有调用外部大模型 API 进行测试集推理或标签生成。除此之外，我们通过 DINOv2 表征、UMAP/HDBSCAN 聚类、MMD/FID 分布距离、MC Dropout 不确定性分析和系统化消融实验对模型表现进行了解释。

🔗 [Yang-Yiming/meteorite-identification](#) 模型权重: [Google Drive](#) [百度网盘 \(提取码: gmrld\)](#)

1 数据集介绍

1.1 数据来源与基本描述

模型的训练集包含 5098 张经过 SAM 分割、bbox 裁剪并 resize 到 288×288 的图像，其中普通石头 2413 张、陨石 2685 张，类别比例相对均衡；另有 3955 张外部 mytest 图片（658 张陨石、3297 张岩石）主要用于分布分析和验证集构造尝试；测试集包含 194 张未标注图像。图像输入为 RGB 格式，因此单张预处理后图像可视为 $288 \times 288 \times 3$ 的像素特征张量，标签为二分类变量。

原始图像尺寸差异较大：训练集图像宽度范围为 133–4896 像素、高度范围为 110–3684 像素；测试集图像宽度范围为 390–6048 像素、高度范围为 289–4096 像素。这也是统一进行目标分割、bbox 裁剪和 resize 预处理的原因之一。

1.2 数据分析

为了理解训练集、外部数据和测试集之间的关系，我们使用 DINOv2 提取图像表征，并结合 UMAP 与 HDBSCAN 进行无监督分析。直接在高维特征上使用 HDBSCAN 容易受到维度诅咒影响，因此采用 UMAP 先降到 15 维，再用 HDBSCAN 聚类（minimum cluster size = 80），最后将聚类结果对原始 UMAP 2D 空间染色进行可视化（见图 1）。该方案比直接 2D 聚类更稳定，也避免了在 2D 空间中过度放大大局结构。




图 1: DINOv2 表征空间中的聚类与 train/test 分布对比

聚类结果显示整体数据可分为若干主要簇，无 mask 图像并没有集中在某一异常区域，而是较均匀地散落在不同簇中。更重要的是，当只在 train set 上 fit UMAP，再将 test set transform 到同一空间时，可以看到中间一大片 test 样本与 train 分布并不重合，其余 test 样本也更多位于 train 分布边缘。这解释了为什么从 train 随机划分得到的验证集分数与真实 test F1 非常不一致。

为了解决这个问题，我们尝试构造更接近 test 的验证集：额外收集约 4000 张图像，其中岩石来自 Kaggle 的 [rocks-dataset](#) 与 [rock-classification](#)，陨石来自 [encyclopedia-of-meteorites.com](#)。随后尝试从候选数据中挑选 test-like validation set，并用 FID 与 MMD 衡量其相对 test 的分布距离。结果如表 1 所示，MMD Greedy 在两个指标上均优于 kNN、Sinkhorn OT、Density uLSIF 和直接使用 train 的基线，MMD 指标相对 train 几乎减半。

表 1: 不同 test-like validation 构造方法的分布距离

方法	FID ↓	MMD ² ↓
MMD Greedy	165.6	0.0235
kNN	209.9	0.0334
Sinkhorn OT	215.0	0.0415
Density uLSIF	216.9	0.0405
Train baseline	224.5	0.0467

不过，实际模型评估表明 test-like validation 仍不能可靠预测 test F1。如图 2 所示，test-like val 仅在低分和分差较大时可信，在最后的小幅调优阶段几乎毫无参考价值。因此我们只把它用于初步确定 baseline，最后仍主要参考 Kaggle F1 做调优。




图 2: test-like val 与真实 test F1 的关系。低分或差距较大时仍有参考价值；进入高分小幅调优后，代理分数几乎不能排序模型。

1.3 数据预处理

我们使用 SAM 对图像中的主要石头目标进行分割，prompt 为 “the main stone or rock in picture”，随后根据 mask 中非零区域提取 bbox，并加入约 10% margin 做裁剪。这样 train 数据集与 test 对齐。引入该预处理使 F1 分数从 0.64516 提升到 0.70222。在修复了一处代码 bug 后（mask+resize 导致背景并不为纯黑），分数进一步上升至 0.73684。

一个有趣现象是，训练时使用黑底图像，但推理时仍在原始测试图像上预测效果更好；若测试时也转为黑底，F1 下降到 0.72072。这表明黑底并不是简单的 train/test 域对齐手段，而更像是一种迫使模型关注石头本体的隐式正则化。

2 模型设计与实现

2.1 整体框架

模型侧使用预训练视觉 backbone 加线性分类头直接输出陨石概率，训练采用两阶段微调，先冻结 backbone 防止随机初始化的分类头扰乱已有权重，再使用分层学习率进行微调；最后，我们使用轻微的阈值搜索和模型集成进一步提升性能。

推理阶段对每个测试样本输出 meteorite 概率 p_i ，根据阈值 τ 生成标签。单模型提交只搜索 τ 来让正负例数均衡；集成提交则先对多个模型概率做加权平均，再搜索统一阈值。这个设计保持了系统的可解释性，也方便后续比较不同 backbone、训练策略和集成权重的贡献。

2.2 模型选择

最终模型以 ConvNeXt 为主干网络。我们最初比较了 DINOv3、EfficientNet 和 ConvNeXt 系列：DINOv3 表征对无监督聚类 and 分布分析很有用，但直接作为分类 backbone 时在本任务上的提交分数不如 ConvNeXt；EfficientNet 训练稳定、参数效率高，但对局部纹理和强分布偏移的适应性也弱于 ConvNeXt。ConvNeXt 同时保留 CNN 的局部归纳偏置和现代网络的训练稳定性，因此成为后续主线。

在 ConvNeXt 内部，我们继续比较 Tiny、Small、Base 以及 ConvNeXt V2。在当前训练数据量下 Tiny 的表现最好，说明小模型在有效标注样本有限时更不容易过拟合；Small 只有在后续引入更多 texture patch 采样、restart 训练和集成后才体现出更高上限；Base 在当前数据规模下过拟合明显；ConvNeXt V2 在 SGD、小数据和当前归一化设置下表现很差。

2.3 实验设置与训练配置

Baseline 训练配置如表 2 所示。相比于第一阶段继承的初始基线，我们将输入分辨率提高到 288px，优化器改为 SGD + Nesterov，并使用 cosine restart 调度；SGD 虽然训练更慢，但在当前小数据任务上泛化更稳定。

表 2: Baseline 训练配置

配置项	取值
输入分辨率	288px
bbox margin	0.1
Backbone	ConvNeXt Tiny/Small/Base
Optimizer	SGD + Nesterov, momentum = 0.9
Backbone LR / Head LR	3×10^{-4} / 3×10^{-3}
Weight decay	0.05
LR scheduler	cosine 或 cosine restart ($T_0 = 10$, min LR 10^{-6})
Dropout / Label smoothing	0.1 / 0.1
LLRD decay	0.8
Batch size	10-32, 视模型规模调整

2.4 不确定性与验证可靠性分析

在分布偏移明显的情况下，我们额外尝试用 MC Dropout 估计不确定性：在 classifier dropout 层进行 50 次前向传播，统计概率均值、标准差、entropy 与 mutual information。结果显示 MC std 均值约 0.05，mutual information 均值约 0.0062，entropy 大于 0.69 的不确定样本约占 11.3%，但其中仍有约一半预测正确。因此 MC Dropout 不能稳定改善决策，只作为概率校准困难的诊断证据。

2.5 主要结果展示与分析

图 3 展示了所有有明确 test F1 的实验轨迹。灰色点表示尝试过但未成为当前最好结果的实验，绿色点和阶梯线表示不断刷新的 running best。可以看到，前期实验主要通过后处理和提交侧修正将分数推进到 0.75126；随后大量训练实验并未立即超过该分数，但 texture、scaling 和 ensemble 逐步形成主线，最终将 F1 推到 0.81633。



图 3: 项目整体实验进展：灰点为未采用尝试，绿点为刷新最好测试 F1 的实验。

表 3 总结了主要方法的性能演进。最终三模型集成由 ConvNeXt Small restart 模型、ConvNeXt Tiny 纹理模型和 ConvNeXt Small cosine 模型组成，权重分别为 0.62、0.28 和 0.10，最佳阈值约为 0.44，最终 F1 为 0.81633。

表 3: 主要实验结果与性能演进

方法	F1	增量	说明
初始基线	0.70222	–	后续实验的起点分数
bbox_crop_masked + SGD	0.73684	+0.03462	黑底 mask 预处理，降低背景噪声
纹理 valid_patch	0.73832	+0.00148	强化局部纹理学习
ConvNeXt Small + repeat=2	0.75455	+0.01623	模型规模与 patch 数量更匹配
Small + repeat=2 + restart	0.79365	+0.03910	最强单模型，epoch 10
三模型加权集成	0.81633	+0.02268	Small/Tiny 与不同调度互补

模型存在明显的验证/测试不一致问题，因此仅依赖离线验证集容易误导。TTA、多 patch 推理和 model soup 均未带来收益，说明有效提升主要来自训练数据视角和模型互补性，而不是推理时的平均技巧。Small + repeat=2 + cosine restart 的单模型已经超过此前多模型集成，说明合适模型规模与采样策略对性能贡献最大。最终集成不是简单平均所有模型，而是选择互补性最强的三个模型使用 0.62:0.28:0.10 权重。最终阈值约 0.44，预测正例数约 110。

3 实验探索、改进与优化

3.1 优化器、学习率与 restart

我们一直采用 AdamW 作为优化器，但以第二章中的 baseline 设置为基础，SGD + cosine restart 将单模型测试 F1 提升到 0.73684，高于 0.70222 的初始基线。说明相比 AdamW，SGD 的隐式正则化更强，在当前小数据和强分布偏移场景下更容易得到可泛化的决策边界。

普通 cosine 调度较稳定，但容易在当前盆地内收敛；cosine restart 会周期性提高学习率，促使模型跳出局部区域重新探索。实验中我们观察到 restart 边界附近 val F1 有明显振荡，但某些 restart 前的 epoch 会出现很强的测试性能峰值。例如 sweep_baseline 在 epoch 28 达到 0.73684，而 last checkpoint 只有 0.71818；small_rpt2_restart_40ep 在 epoch 10 达到 0.79365，成为最终最强单模型。代价是 checkpoint 选择更敏感，必须保存并评估多个 epoch。




图 4: 最强单模型训练曲线

3.2 Texture patch: 从全局形状转向局部纹理

第二类优化是 texture patch 训练。我们在每张图上随机采样有效 patch，并限制空白区域占比，迫使模型在局部纹理上建立判别能力。早期 texture 单模型 F1 为 0.73832，提升幅度不大，但 patch 方法给予了更强的 augmentation 和 scale 能力。

我们进一步测试了 patch 尺度。较大 patch (scale 0.30–0.70) 使模型重新接近全图训练，test F1 约 0.70339；较小 patch (scale 0.08–0.30) 缺少足够语义信息，test F1 约 0.68889。最终使用中等尺度 patch (约 0.18–0.55)，在保留局部纹理的同时避免完全丢失石头结构。

另一个重要问题是每张图每个 epoch 采样多少 patch。对 ConvNeXt Tiny，固定总训练样本量为 362K，repeat=2、4、8 分别对应 20、10、5 epochs，F1 分别为 0.69841、0.69159、0.72549。虽然 repeat=8 只训练 5 epochs，却优于较低 repeat，说明“每个 epoch 看到更多不同 patch”比“在同一视角上训练更多轮”更有效。这一发现随后被用于模型规模扩展。

表 4: Texture patch 的 repeat 与模型规模实验

实验	模型	参数量	repeat/epoch	Test F1
repeat sweep	ConvNeXt Tiny	28M	2 / 20	0.69841
repeat sweep	ConvNeXt Tiny	28M	4 / 10	0.69159
repeat sweep	ConvNeXt Tiny	28M	8 / 5	0.72549
scale sweep	ConvNeXt Tiny	28M	1 / 40	0.73832
scale sweep	ConvNeXt Small	50M	2 / 40	0.75455
scale sweep	ConvNeXt Base	89M	3 / 40	0.67857

3.3 模型规模、数据量与最终单模型突破

第三类优化是 scaling law 式的模型/数据配比。ConvNeXt Small 参数量约为 Tiny 的 1.78 倍，因此我们使用 repeat=2 让每张图片在每个 epoch 中产生更多 patch 视角。tex_small_rpt2 的单模型 F1 达到 0.75455，显著优于 Tiny texture。进一步训练 small_rpt2_restart_40ep 后，epoch 10 的单模型 F1 达到 0.79365，已经超过此前 4 模型集成结果。

ConvNeXt Base 效果下降，可能因为 repeat 较高时以出现重复问题，再次过拟合。

3.4 模型集成：从平均到互补性选择

我们尝试了多种集成方法，用 texture 模型和全图模型互补达到 0.76923，随后四模型集成 sm + tex + base + s256 达到 0.78788，但进一步分析发现全图模型反而会稀释强模型信号。最终三模型组合只保留 small_rpt2_restart、sweep_texture 和 tex_small_rpt2 三个纹理模型，权重 0.62/0.28/0.10，取得 **0.81633**。如，三模型集成让曲线更加平缓，降低模型方差。




图 5: 最终三模型集成在测试样本上的概率叠加。黑线为加权 ensemble 概率，三条浅色曲线为单模型概率，背景颜色表示真实类别。

3.5 负结果与失败路线

表 5 总结了部分我们尝试过但失败的方法。它们共同说明，本任务的核心瓶颈不是推理增强不足，而是训练分布与测试分布的偏移、有效标签少以及局部纹理判别的不稳定。

表 5: 尝试但未纳入最终方案的方法

方法	代表结果	决策	主要原因
白底 masked crop	0.71429	抛弃	低于黑底，亮度分布偏移较强
大/小 patch 变体	0.70339 / 0.68889	抛弃	大 patch 接近全图，小 patch 丢失判别纹理
Multi-patch 推理	0.721 / 0.717	抛弃	多 patch 平均稀释单 patch 判别信号
TTA 4way/8way	约 0.737	抛弃	与 multi-patch 类似，平均后收益为负
Model Soup	0.65193 / 0.711	抛弃	restart 振荡导致权重空间不适合简单平均
ConvNeXt V2	0.66932 / 0.67500	抛弃	小数据 + SGD 下表现低迷，可能与归一化/训练动力学有关
RandAugment / MixUp	0.71552 / 0.70769	抛弃	常规增强不能解决核心分布偏移
MC Dropout	F1 波动约 0.01	抛弃	不确定性估计不能稳定改善决策
多阶段逐步解冻 backbone	0.42857	抛弃	训练难度过大，调参要求高

3.6 未来工作

后续可以从六个方向继续推进：其一，围绕 Qwen-VL 构建 SFT 数据集与 agentic 工作流，用 VLM 生成困难样本描述、检索 query 和候选标签，再经人工/规则审核形成高质量监督数据；其二，用 DINOv2 表征主动收集与 test 更接近的外部图片，并按特征簇、来源、类别和纹理类型分组追加，持续检查类别平衡与分布距离；其三，尝试 OHem 或离线 hard negative mining，基于 baseline checkpoint 强化高置信误判负样本；其四，系统复核训练/推理 infra，排查数据划分、预处理一致性、归一化、阈值搜索和 label mapping 等潜在问题；其五，避免一次性混入大规模外部数据，采用可审计的分批扩充；其六，将手工 ensemble 升级为 LightGBM、逻辑回归或 stacking 等学习式融合，但前提是先建立可靠的 validation protocol，避免过拟合代理验证集。

4 结论

本项目完成了陨石图像二分类任务的系统优化。最终方案以 ConvNeXt Small/Tiny 为基础，通过黑底 mask 预处理、SGD + Nesterov、纹理 patch 训练、模型规模与采样次数配比，以及加权概率集成，将测试 F1 从 0.70222 提升到 0.81633。项目的主要经验是：在小样本且存在分布偏移的图像任务中，验证集分数未必可靠；相比复杂后处理，更有效的是让模型在训练阶段看到更接近判别本质的局部纹理，并保留不同模型之间的互补性。

参考文献

[1] Z. Liu et al. A ConvNet for the 2020s. *CVPR*, 2022.

[2] A. Kirillov et al. Segment Anything. *ICCV*, 2023.

[3] M. Oquab et al. DINOv2: Learning Robust Visual Features without Supervision. *TMLR*, 2024.

- [4] L. McInnes, J. Healy, J. Melville. UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction. 2018.
- [5] R. J. G. B. Campello, D. Moulavi, J. Sander. Density-Based Clustering Based on Hierarchical Density Estimates. *PAKDD*, 2013.
- [6] R. Wightman. PyTorch Image Models. [pytorch-image-models](#)
- [7] Kaggle datasets: [rocks-dataset](#) and [rock-classification](#). Accessed 2026-06-04.
- [8] Encyclopedia of Meteorites. [encyclopedia-of-meteorites.com](#)